

RELATÓRIO TÉCNICO

**Sistema de Extração de Notas Fiscais Eletrônicas (NFe)
On Premises com Ollama**

GRUPO MINDMESH

SÉRGIO EDUARDO PALMIERE – palmiere@hotmail.com

JOEL FERNANDES - fernandaave@gmail.com

FERNANDA AVE - fernandesjoelalberto@gmail.com

1. O que é o Sistema NFe Extractor
2. Arquitetura Geral
3. Público Alvo
4. Justificativa do Tema Escolhido
5. Componentes Principais
6. Funções dos Arquivos Principais
7. Agentes de IA (CrewAI e LangChain)
8. Funcionalidades Principais
9. Fluxograma de Processamento
10. Aplicações Práticas
11. Conclusões e Recomendações
12. Apêndice e Especificações Técnicas
13. Links

1. O que é o Sistema NFe Extractor

O Sistema NFe Extractor é uma ferramenta completa on presmisses e integrada para processamento, análise e validação de Notas Fiscais Eletrônicas (NFe) brasileiras. Utiliza técnicas avançadas de extração de dados, processamento de linguagem natural (NLP) e inteligência artificial para automatizar o fluxo de trabalho fiscal. Objetivo Principal: Extrair, validar, classificar e analisar documentos fiscais (PDF, XML, CSV) com alta precisão e velocidade, utilizando modelos de IA local para garantir privacidade e reduzir custos operacionais.

Características principais incluem suporte a múltiplos formatos, OCR integrado com Tesseract, IA local com Ollama, interface web com Streamlit e agentes inteligentes para automação.

2. Arquitetura Geral

O sistema segue uma arquitetura em camadas com separação de responsabilidades. Abaixo está o diagrama simplificado representando camadas: Apresentação (Streamlit), Negócios (módulos de processamento), Integração IA (Ollama) e Dados (entrada/saída).

Arquitetura Geral - NFe Extractor (visão simplificada)




Figura 1: Diagrama de Arquitetura.

3. Público Alvo

O Sistema NFe Extractor foi desenvolvido para atender múltiplos públicos-alvo:

- **Empresas de Contabilidade:** Que precisam processar grande volume de NFe de múltiplos clientes com precisão e compliance;
- **Departamentos Fiscais:** Áreas de CFO/Controllers que realizam auditoria interna e conformidade fiscal;
- **Órgãos Reguladores:** Receita Federal e secretarias estaduais para validação em larga escala e detecção de fraudes;
- **Empresas Fintech/ERP:** Provedores de software que integram processamento fiscal em suas plataformas;
- **Consultores Fiscais:** Profissionais que precisam acelerar análises e recomendações estratégicas.

4. Justificativa do Tema Escolhido

Por que isto é importante:

- O Brasil gera bilhões de documentos fiscais eletrônicos anualmente. Processá-los manualmente é inviável economicamente;
- Conformidade fiscal é mandatória, mas ferramentas atuais são caras, dependem de terceiros e violam privacidade de dados;
- Fraude fiscal é um problema sistêmico que causa bilhões em perdas ao governo e prejudica empresas honestas.
- Redução de Custos: Economia 70-90% em tempo de processamento, eliminando dependência de consultores externos;
- Privacidade Total: Execução local (Docker) mantém dados sensíveis isolados, sem envio a terceiros;
- Conformidade Garantida: Validações automáticas reduzem risco de não-conformidade e multas regulatórias; Detecção de Anomalias: IA identifica padrões suspeitos e operações de risco antes que causem problemas;

- Escalabilidade: Processamento paralelo permite tratar milhões de documentos em horas, não dias ou semanas.

5. Componentes Principais

O Sistema NFe Extractor v2.1 consiste em múltiplos componentes integrados, cada um responsável por uma função específica no pipeline de processamento.

- Ollama: Ferramenta on premisses que permite processar grandes quantidades de notas fiscais localmente. Principais arquivos: Dockerfile, docker-compose.yml, docker-entrypoint.sh e scripts de setup.
- Streamlit: Interface web responsiva para upload e processamento, com dashboard e exportação de resultados.
- Processamento de NFe: Conjunto de módulos responsáveis pela extração, normalização, validação e análise (nfe_extractor, nfe_advanced_extractor, nfe_agents, nfe_dashboard_analytics, nfe_integration_bridge).
- O ollama permite a utilização de diferentes modelos de LLM, neste projeto devido a limitações de hardware optou-se pela utilização do modelo Llama3.2: 3B que possui alta eficiência e necessita de pouca memória de vídeo para rodar localmente. O App comunica com Ollama via api (ex.: <http://ollama:11434>).

6. Funções dos Arquivos Principais

Tabela resumida de arquivos e responsabilidades: app.py (interface), main.py (orquestração), nfe_extractor.py (extração), nfe_advanced_extractor.py (processamento avançado), nfe_agents.py (agentes CrewAI), nfe_dashboard_analytics.py (analytics), nfe_integration_bridge.py (integração), ollama_integration.py (integração Ollama).

7. Agentes de IA (CrewAI e LangChain)

O sistema utiliza CrewAI para agentes cooperativos com papéis definidos e LangChain para cadeias de prompts e contexto. Exemplos de agentes: ValidadorFiscal, ClassificadorOperacao e AnalisadorRisco.

Fluxo: agentes são instanciados pelo coordenador, processam NFe em paralelo, LangChain gerencia o contexto e Ollama fornece respostas via prompts.

8. Funcionalidades Principais

- Extração de Dados: Suporte a XML, PDF (OCR) e CSV com normalização automática.

- Validação Fiscal: Verificações automáticas, cálculos e assinaturas.
- Análise com IA: Classificação automática, detecção de anomalias e chat interativo.
- Dashboard e Relatórios: Visualização, séries temporais, KPIs e export.

9. Fluxograma de Processamento

Fluxo completo de uma NFe no sistema: do upload do usuário até a saída consolidada (CSV/Excel/PDF). A figura a seguir ilustra o fluxo de processamento.

Fluxo de Processamento - NFe




Figura: Fluxograma de Processamento.

10. Aplicações Práticas

- Auditoria Fiscal: automatiza análises de conformidade, reduzindo esforço manual.
- Análise de Fraude: detecção de padrões suspeitos e pontuação de risco.
- Gestão de Fornecedores: monitoramento de performance e recomendações.

- Conformidade Regulatório: validação e geração de relatórios para órgãos.

11. Conclusões e Recomendações

Resumo executivo: solução completa, portátil e privada, com redução alta de custos e tempo de processamento. O funcionamento on premisses, garante a segurança dos dados, contudo exige que o usuário detenha um hardware capaz de executar a ferramenta.

Recomendações de curto, médio e longo prazo para implantação em produção, integração com ERPs e expansão de capacidades. Criar ambiente dockerizado, e avaliar uso de novas versões das bibliotecas. Exportar o resultado das extrações diretamente para um banco de dados.

12. Apêndice: Especificações Técnicas

- Stack: Python 3.11, Streamlit, Ollama, CrewAI, LangChain, Tesseract, Pdfplumber, Pandas.
- Requisitos de hardware: mín. 2 CPUs/4GB, recomendado 4+ CPUs/8GB, produção 8+ CPUs/16GB.
- Performance estimada: extração XML ~2-3s, OCR PDF 15-30s por página, validação IA 5-10s por NFe.
- Desenvolvido com : Python • Ollama • Streamlit • CrewAI • LangChain • Llama 3.2: 3B

13. Links

Vídeo de Apresentação da Ferramenta: <https://youtu.be/SL45fLRQc4s>

Repositório do Projeto: <https://github.com/SEPalmiere/I2A2-Agentes-Inteligentes/tree/main/Projeto%20Final%20-%20Artefatos>